

06. 테스트 계획 및 결과 보고서

발표 보고서 제출 요구 항목 「테스트계획 및 결과 보고서」의 정보이다. 기준일 2026-08-04

0. 한 장 요약

테스트는 레이어별로 나눠 설계했다 — 데이터 → 검색 → 리랭킹 → 판정 → 코드 계약 → 보안 → end-to-end 응답 품질 순으로, 아래쪽 레이어의 결함이 위쪽 레이어의 좋은 점수로 가려지지 않게 각 층을 독립적으로 측정한다.

계획	레이어	결과	근거
A-1	데이터 품질 게이트	✅ 완료	Part B-1
A-2	검색(임베딩) 성능	✅ 완료	Part B-2
A-3	리랭커 성능	✅ 완료	Part B-3
A-4	검색 비회귀	✅ 완료	Part B-4
A-5	운영 연결 스모크 테스트	✅ 완료	Part B-5
A-6	코드 레벨 요구사항 트레이서빌리티	✅ 완료(REQ 20개)	Part B-6
A-7	보안 10케이스	✅ 완료	Part B-7

Part A. 테스트 계획

A-1. 목적과 원칙

이 프로젝트는 보험 약관 판정이라는, 틀리면 사용자에게 실질적 피해가 갈 수 있는 도메인을 다룬다. 그래서 테스트 계획은 "평균 점수가 높은가"보다 "가장 위험한 실패 모드가 없는가"를 우선한다.

원칙	적용
층별 독립 측정	검색-리랭커-판정을 한 점수로 묻치지 않고 각각 측정해, 어디서 실패했는지 추적 가능하게 한다
근거 없는 답변 금지	근거 0건이면 생성하지 않고 기권한다(abstention) — 정확도보다 안전성 우선
표본 부족 시 비율을 숨긴다	표본이 작으면 점추정을 단정하지 않고 신뢰구간이나 "확인 불가"로 표기한다
판본 불확실성 고지	계약 판본이 확정되지 않으면 그 사실을 사용자에게 그대로 알린다
무효 결과도 기록	모델이 상수 점수를 낸 것처럼 명백한 이상 결과는 "낮은 성능"이 아니라 별도 원인으로 분류한다

A-2. 테스트 레이어와 방법론

레이어	무엇을 보는가	방법	기준
데이터 품질 게이트	수집·전처리·OCR 승격이 숫자를 지어내지 않는가	입력 계보 대조, 숫자 환각 방지 검사, 결정성 재빌드, 사람 승인	불일치 0건
검색(임베딩) 성능	질의·조항 검색이 실제 조항을 찾는가	21회 비교 측정(fp16 17회+4bit 4회), 부트스트랩 2,000회 95% CI	MRR-Recall-잘림률
리랭커 성능	검색 결과 재정렬이 실제로 정답을 위로 올리는가	5종 실측, 417질의·8,273 pair, paired bootstrap 10,000회	Hit@1·MRR@10·대체표현 Hit@1
검색 비회귀	새 데이터 반영이 기존 검색 품질을 해치지 않는가	기존 417질의 gold rank 재확인	gold rank 변화 0건
운영 연결 스모크 테스트	배포된 릴리스가 실제로 서비스 가능한 상태인가	API readiness·회귀 테스트·후보 registry fail-closed 검증	ready=true, 회귀 통과
코드 레벨 요구사항 트레이서빌리티	각 기능 요구사항이 테스트로 뒷받침되는가	REQ ID ↔ pytest 노드 매핑, 노드 존재·collect 가능 여부를 별도 메타테스트로 검증	REQ 20개 전량 매핑
보안 케이스	프롭트 인젝션·권한 우회 등 알려진 위협에 방어가 있는가	보안 10케이스, 각 케이스를 대응 테스트 노드에 매핑	10케이스 전량 매핑

Part B. 테스트 결과

B-1. 데이터 품질 게이트

01 수집데이터 및 전처리.md §6 기준.

검증 층	검사	결과
입력 계보	이미지 SHA·모델 revision·archive·alias 대조	832/832 입력 일치, 예상 밖 stale 1건 quarantine
숫자 환각 방지	OCR 금액·비율 토큰이 같은 페이지 native text에 존재하는지	금액 4,172/4,172 + 비율 4,124/4,124 = 8,296/8,296
grid·근거	bbox 4좌표, rowspan/colspan, ragged-span mismatch	invalid bbox 0
accepted 비회귀	S6 accepted clauses와 S7 결합본 비교	204,098개 내용 mismatch 0
결정성	같은 입력으로 S7 재빌드	page+clause 2,734파일 전부 unchanged
manifest	S7 1,367문서·tree digest 재검증	어긋남 0
격리	candidate의 serving/citation·색인 유입	승인 전 0건
사람 승인	29패턴 원문 대조	approve 24·fix 5

숫자 토큰 8,296/8,296 일치는 "OCR이 새 숫자를 지어내지 않았다"는 검사이지, 그 숫자가 올바른 행·헤더에 연결됐다는 precision을 의미하지 않는다 — 그래서 최종 축 소속은 사람 승인을 요구했다.

B-2. 검색(임베딩) 성능

05C 사용 LLM 모델.md §3 기준. 측정 21회(fp16 17회+4bit 4회), 질의 3종(제목 검색 145문항·뒷부분 검색 60문항·면책 표현 16문항), 짝비교 + 부트스트랩 2,000회 95% 신뢰구간.

모델	MRR	R@10	뒷MRR	면책MRR	잘림
Snowflake/snowflake-arctic-embed-l-v2.0	0.557	0.697	0.290	0.288	0.0%
dragonkue/snowflake-arctic-embed-l-v2.0-ko (현 배포)	0.549	0.703	0.317	0.341	0.0%
jhgan/ko-sroberta-multitask (옛 배포)	0.434	0.607	0.133	0.077	83.7%

핵심 결론: 결정적이었던 건 순위가 아니라 **잘림**이었다 — 옛 배포(ko-sroberta@128토큰)는 조항의 83.7%가 잘렸고, 면책 문구는 조항 뒤쪽에 있어 뒷부분 MRR이 4.4배(0.077→0.341) 개선됐다. 상위 그룹 간 순위는 95% 신뢰구간이 겹쳐 통계적 우열보다는 "예비 후보 축소"로 읽는다.

B-3. 리랭커 성능

05C 사용 LLM 모델.md §4 기준. 평가 입력: 원본 청크 145,220개, 평가 질의 417개(retrievable 314), pair 8,273개.

모델	Hit@1	MRR@10	대체표현 Hit@1	처리량(pair/s)
Qwen/Qwen3-Reranker-4B (채택)	84.71%	0.9104	73.47%	11.36
BAAI/bge-reranker-v2-m3	78.03%	0.8562	50.00%	40.69
Alibaba-NLP/gte-multilingual-reranker-base	71.02%	0.8040	45.92%	47.27
Qwen/Qwen3-Reranker-0.6B	71.02%	0.8021	33.67%	7.79
jinaai/jina-reranker-v2-base-multilingual	66.56%	0.7777	33.67%	356.56
dense 기준선(리랭크 전)	64.65%	0.7684	17.35%	—

paired bootstrap 10,000회(4B vs BGE): 전체 Hit@1 +6.69%p [95% CI +1.59, +11.78], **대체표현 Hit@1 +23.47%p [+11.22, +35.71]** — 사용자가 약관 문구 그대로 묻지 않는 "대체표현" 질의에서 차이가 갈랐다. 다만 4B는 12GB 상주 예산에 안 들어가 오프라인 release로만 쓰고 실시간 경로는 기본 OFF다.

무효 결과 처리: Querit/Querit-4B 는 로드 오류로 8,273개 점수가 전부 동일값이 나와 "성능 나뽀"이 아니라 `checkpoint/scoring-adapter incompatibility` 로 분류하고 이후 점수 게이트(membership-finite-non-constant)를 추가했다.

B-4. 검색 비회귀

01 수집데이터 및 전처리.md §6 기준. 기존 417질의 top20·리랭크 기준으로, 승인 OCR fact가 검색에 실제 들어오면서(6질의·23 pair 유입) 기존 **gold rank 변화 0**건을 확인했다. S7.1 적용 전후 Hit@1·MRR@10은 동일 — 새 fact가 기존 검색 품질을 훼손하지 않았음을 확인한 비회귀 결과다.

B-5. 운영 연결 스모크 테스트

docs/reports/2026-08-04_산출물_운영연결_및_스모크테스트.md 기준.

검사	결과
활성 release	r2026-08-04-clause-s7.1-arctic-ko-ocr-approved
승인 OCR occurrence	850
미승인 candidate DB occurrence	0
승인 벡터 rank 1 내용 해시	일치
top20 반환 수	20
관련 회귀 테스트	73건 통과
/api/health/ready	ready=true

후보(candidate) registry는 fail-closed로 설계돼, 파일 손상·해시 불일치·행 수 불일치·승인 상태 변경 중 하나만 있어도 readiness가 실패하도록 검증돼 있다.

B-6. 코드 레벨 요구사항 트레이서빌리티

tests/requirements_matrix.yaml 기준, MUST 요구사항 20개가 각각 pytest 노드에 매핑돼 있고, 매핑마다 "그 테스트가 요구사항을 직접 확인하는지"에 대한 근거가 붙는다. 매트릭스 자체의 무결성(노드 존재·collect 가능·skip/xfail 아님)은 test_requirements_matrix.py 가 검증한다.

요구사항 ID	내용	결과
REQ-QA-BASE-01	결정론 테스트 기준선 재현	DONE
REQ-RAG-04	AnswerQuestion — 근거 기반 답변 + 출처 인용	DONE
REQ-RAG-05	근거 없음 → abstention(환각 억제)	DONE
REQ-RAG-01	RAG 품질 고정 — Hit@3≥0.85·abstention	DONE
REQ-RAG-03	Hybrid(dense+lexical) RRF 결합	DONE
REQ-RAG-RERANK-01	Reranker 재정렬	DONE
REQ-LLM-REG-01	모델 ID 하드코딩 금지·registry 검증	DONE
REQ-OPS-01	기동/데이터 분리 — readiness 보고	DONE
NFR-OBS-01	관측성 — X-Trace-ID 전파	DONE
REQ-VEC-01 / 02	pgvector-FAISS parity / 미준비 시 명시 오류	DONE
REQ-GRAPH-DESIGN-01 / 01 / 02	GraphRAG 설계·구현·그래프+벡터 결합	DONE
REQ-MCP-01	MCP-REST parity	DONE
REQ-AUTH-01	RBAC 401/403/200	DONE
REQ-ADMIN-01 / 02	관리자 API fail-closed·부트스트랩	DONE

커머스(주문·명등·에이전트·CoT 관련 REQ-COM-01~03 등 6개)는 레거시(v3 커머스)로 격리돼 있어 이 보험 RAG 제품의 커버리지 범위에서 제외한다. 결정론 테스트 기준선은 최초 182개에서 현재 320개로 늘었다.

B-7. 보안 케이스

tests/security_cases.yaml 기준, v3.1 §6.2 원문을 승계한 보안 10케이스 중, 이 보험 RAG 제품 범위에 해당하는 4개는 다음과 같다.

ID	내용	결과
TEST-SEC-001	문서 내 "시스템 지시 무시" 문구를 도구 지시로 실행하지 않음	DONE
TEST-SEC-004	USER가 admin API 접근 시 403	DONE
TEST-SEC-007	ingest가 허용 확장자만 수집, 경로 이동 거부	DONE
TEST-SEC-008	MCP 오류 taxonomy 유지 + 비밀(config) 비노출	DONE

나머지 6케이스(결제·주문·idempotency·에이전트 쓰기차단)는 레거시(v3 커머스) 범위로, 이 제품에는 해당하지 않는 기능이라 별도 커버리지로 관리한다. 위협모델은 "인터넷 노출 서비스가 아니라 학습·포트폴리오용 API"라는 전제를 명시하고 있다.

종합

데이터 품질 게이트, 검색(임베딩) 성능, 리랭커 성능, 검색 비회귀, 운영 연결 스모크 테스트, 코드 레벨 요구사항 트레이서빌리티, 보안 케이스까지 7개 레이어 전부 실측 수치와 검증된 기록으로 뒷받침된다.